

ĐỒ ÁN 1

TIỀN XỬ LÝ DỮ LIỆU

Phân tích thống kê – Thiết kế Pipeline – Phân tích & Đánh giá tác động

Môn học: Khai thác dữ liệu và ứng dụng

Mã HP: CSC14004

Học kỳ: HỌC KỲ 2 – 2025/2026

Thông tin giảng viên

GV Thực hành: Th.S Nguyễn Thị Thu Hằng

Th.S Nguyễn Ngọc Đức

Th.S Lê Nhật Nam

E-mail: ntthuhang0131@gmail.com

{nnduc, lnnam}@fit.hcmus.edu.vn

Bộ môn: Khoa học máy tính

Tài liệu này dành riêng cho mục đích học thuật.

Mục lục

1	MỤC TIÊU ĐỒ ÁN	2
2	MÔ TẢ ĐỒ ÁN	2
2.1	Phần 1: Tiền xử lý dữ liệu ảnh số	2
2.1.1	Lựa chọn tập dữ liệu	2
2.1.2	Phân tích thống kê tập dữ liệu	3
2.1.3	Các kỹ thuật tiền xử lý và phân tích tác động	3
2.2	Phần 2: Tiền xử lý dữ liệu dạng bảng	4
2.2.1	Lựa chọn tập dữ liệu	4
2.2.2	Phân tích thống kê khám phá (EDA chuyên sâu)	4
2.2.3	Các kỹ thuật tiền xử lý và đánh giá định lượng	4
2.3	Phần 3: Tiền xử lý dữ liệu văn bản	5
2.3.1	Lựa chọn tập dữ liệu	6
2.3.2	Phân tích thống kê văn bản (Text EDA)	6
2.3.3	Các kỹ thuật tiền xử lý và phân tích tác động	6
2.4	Phần 4: Tiền xử lý dữ liệu chuỗi thời gian	7
2.4.1	Lựa chọn tập dữ liệu	7
2.4.2	Phân tích khám phá chuỗi thời gian	7
2.4.3	Các kỹ thuật tiền xử lý nâng cao	8
3	YÊU CẦU TRIỂN KHAI	8
3.1	Yêu cầu kỹ thuật	8
3.2	Yêu cầu báo cáo PDF	9
4	TỔ CHỨC ĐỒ ÁN	9
5	TIÊU CHÍ CHẤM ĐIỂM	10
6	NỘP BÀI	11

1. MỤC TIÊU ĐỒ ÁN

Tiền xử lý dữ liệu không chỉ là bước làm sạch dữ liệu đơn giản – đây là một quy trình kỹ thuật đòi hỏi hiểu biết sâu về thống kê, thiết kế hệ thống và khả năng lập luận phân tích. Đồ án này yêu cầu sinh viên không chỉ biết cách *áp dụng* các kỹ thuật tiền xử lý mà còn có khả năng *giải thích bằng các công cụ thống kê, so sánh có kiểm soát và thiết kế pipeline có thể sử dụng lại được* cho các loại dữ liệu sau:

- **Dữ liệu ảnh:** Biến đổi không gian, phân tích phân phối đặc trưng, augmentation có kiểm soát.
- **Dữ liệu bảng:** Phát hiện ngoại lai, kiểm định thống kê, giảm chiều dữ liệu để trực quan hoá/ trích chọn đặc trưng.
- **Dữ liệu văn bản:** Tiền xử lý theo đặc tính ngôn ngữ, biểu diễn ngữ nghĩa, phân tích tính thừa của dữ liệu.
- **Dữ liệu chuỗi thời gian:** Kiểm định tính dừng, phân rã chuỗi, phát hiện dị thường/ bất thường.

Lưu ý

Ký hiệu trong đồ án: **[Bắt buộc]** chỉ yêu cầu bắt buộc với tất cả nhóm; **[Nâng cao]** chỉ yêu cầu nâng cao mang lại điểm thưởng bổ sung trong phần đó.

2. MÔ TẢ ĐỒ ÁN

Sinh viên làm việc theo nhóm từ 2 đến 5 thành viên. Mỗi phần yêu cầu sinh viên không chỉ cài đặt kỹ thuật mà còn phải thực hiện **phân tích ablation** (thay đổi từng thành phần và đo lường ảnh hưởng) và **kiểm định thống kê** để củng cố lập luận.

2.1. Phần 1: Tiền xử lý dữ liệu ảnh số

2.1.1. Lựa chọn tập dữ liệu

Sinh viên chọn **một** tập dữ liệu ảnh. Tập dữ liệu phải có **ít nhất 5 lớp** và **ít nhất 5.000 ảnh**. Một số tập dữ liệu gợi ý như sau:

- Ảnh X-quang ngực: [Chest X-Ray Images](#), [NIH Chest X-rays](#)
- [New Plant Diseases Dataset](#)

2.1.2. Phân tích thống kê tập dữ liệu

[Bắt buộc] Trước khi tiền xử lý, sinh viên phải thực hiện **phân tích thống kê mô tả toàn diện**:

- Tính và trực quan hóa phân phối giá trị pixel trên toàn tập (histogram, KDE) theo từng kênh màu.
- Phân tích **mất cân bằng lớp** (class imbalance): tính tỉ lệ mỗi lớp, kiểm tra xem có lớp nào chiếm tỉ lệ vượt mức $3\times$ so với lớp ít nhất không.
- Phát hiện ảnh **trùng lặp hoặc gần trùng** bằng hàm băm perceptual hash (pHash). Báo cáo tỉ lệ trùng lặp và xử lý chúng.
- Phân tích **độ tương phản và độ sáng** toàn cục: tính mean intensity và standard deviation theo lớp, thể hiện qua boxplot phân lớp.

2.1.3. Các kỹ thuật tiền xử lý và phân tích tác động

[Bắt buộc] Sinh viên phải cài đặt đầy đủ, **đo lường định lượng** tác động của mỗi kỹ thuật, và thực hiện **ablation study** bằng cách so sánh kết quả phân loại đơn giản (dùng k -NN hoặc Logistic Regression) trước và sau khi áp dụng mỗi kỹ thuật.

- Thay đổi kích thước và chất lượng ảnh:** Resize về ít nhất **3 kích thước khác nhau** (ví dụ: 32×32 , 64×64 , 128×128). Với mỗi kích thước, tính chỉ số **SSIM** (Structural Similarity Index) và **PSNR** so với ảnh gốc để định lượng mức độ mất mát thông tin. Vẽ đường cong SSIM theo kích thước và biện hộ cho kích thước được chọn.
- Chuyển đổi không gian màu:** Chuyển đổi và so sánh ít nhất **3 không gian màu**: RGB, Grayscale, HSV, và LAB. Với mỗi không gian màu, tính **phương sai giải thích** (explained variance) theo PCA với $k = 50$ thành phần. Thảo luận không gian màu nào bảo toàn thông tin tốt nhất cho bài toán phân loại.
- Chuẩn hóa:** Cài đặt và so sánh **4 phương pháp**: (i) Min-Max $[0, 1]$; (ii) Min-Max $[-1, 1]$; (iii) Z-score toàn tập; (iv) Z-score theo từng kênh (per-channel). Dùng kiểm định **Kolmogorov-Smirnov (KS test)** để đánh giá sự khác biệt phân phối trước và sau chuẩn hóa. Báo cáo p -value và diễn giải ý nghĩa thống kê.
- Tăng cường dữ liệu (Data Augmentation):** **[Bắt buộc]** Cài đặt pipeline augmentation gồm ít nhất **5 phép biến đổi** (lật ngang/dọc, xoay, cắt ngẫu nhiên, thêm nhiễu Gaussian, điều chỉnh độ sáng/tương phản). Sau đó, đánh giá tác động của augmentation đến phân phối đặc trưng bằng cách so sánh t-SNE visualization của tập gốc và tập đã augment.
- [Nâng cao] Phân tích PCA trên không gian đặc trưng ảnh:** Chiếu toàn bộ tập dữ liệu lên không gian PCA. Vẽ **scree plot** và xác định số thành phần cần thiết để giải thích 90%, 95%, và 99% phương sai. Trực quan hóa 2D/3D bằng PCA và t-SNE, tô màu theo nhãn lớp. Thảo luận mức độ tách biệt giữa các lớp.
- [Nâng cao] Phát hiện cạnh và phân tích đặc trưng cục bộ:** Áp dụng Sobel, Prewitt và Canny với ít nhất **2 bộ siêu tham số** mỗi loại. Tính **Edge Density** (tỉ lệ pixel cạnh / tổng pixel) theo lớp và kiểm định sự khác biệt giữa các lớp bằng ANOVA một chiều. Kết luận liệu thông tin cạnh có phân biệt được các lớp hay không.

2.2. Phần 2: Tiền xử lý dữ liệu dạng bảng

2.2.1. Lựa chọn tập dữ liệu

Sinh viên chọn **một** tập dữ liệu bảng có **ít nhất 10 thuộc tính** và **ít nhất 10.000 record**, có sự kết hợp giữa thuộc tính số và phân loại. Một số tập dữ liệu gợi ý như sau:

- [Credit Card Fraud Detection](#) (dữ liệu mất cân bằng cực cao)
- [Credit Card Transactions Fraud Detection Dataset](#)

Lưu ý

Yêu cầu tập dữ liệu: Ít nhất 10 thuộc tính, 10.000 record, có cả thuộc tính số lẫn phân loại, và **tỉ lệ giá trị thiếu** $\geq 5\%$ trên ít nhất một thuộc tính.

2.2.2. Phân tích thống kê khám phá (EDA chuyên sâu)

[Bắt buộc] Trước khi tiền xử lý, sinh viên phải thực hiện EDA theo các bước sau:

- Kiểm tra phân phối:** Với mỗi thuộc tính số, kiểm định **Shapiro-Wilk** (nếu $n \leq 5000$) hoặc **D'Agostino-Pearson** (nếu $n > 5000$). Phân loại từng thuộc tính là phân phối chuẩn hay không chuẩn dựa trên p -value, và sử dụng kết quả này để lựa chọn phương pháp chuẩn hóa phù hợp.
- Phân tích tương quan đa biến:** Vẽ heatmap tương quan Pearson và Spearman. Xác định các cặp thuộc tính có khả năng đa cộng tuyến mạnh (ví dụ: $|r| > 0.9$) và đề xuất xử lý.
- Phân tích giá trị thiếu:** Trực quan hóa ma trận thiếu dữ liệu (missing data matrix) bằng thư viện `missingno`. Kiểm định giả thuyết **MCAR** bằng Little's MCAR test. Phân loại cơ chế thiếu dữ liệu (MCAR/MAR/MNAR) và giải thích.

2.2.3. Các kỹ thuật tiền xử lý và đánh giá định lượng

- Xử lý giá trị thiếu có kiểm soát:** Cài đặt **5 chiến lược điền khuyết**: trung bình, trung vị, mode, k -NN imputation (ví dụ: $k \in \{3, 5, 10\}$), và MICE (Multiple Imputation by Chained Equations). Với mỗi chiến lược, tạo nhân tạo 10% giá trị thiếu bổ sung (MCAR) và tính **RMSE điền khuyết** để đánh giá độ chính xác. Trình bày bảng so sánh tất cả chiến lược và lựa chọn chiến lược tốt nhất có lý giải.
- Phát hiện và xử lý ngoại lai bằng nhiều kỹ thuật:** **[Bắt buộc]** Cài đặt và so sánh **4 phương pháp phát hiện ngoại lai** sau:
 - IQR và Z-score
 - **Isolation Forest** với $\text{contamination} \in \{0.01, 0.05, 0.1\}$
 - **Local Outlier Factor (LOF)** với $n_{\text{neighbors}} \in \{10, 20, 50\}$

- **DBSCAN** (gom cụm ngoại lai)

Với mỗi phương pháp, báo cáo tỉ lệ phát hiện ngoại lai và sự chồng chéo giữa các phương pháp (ví dụ: Jaccard similarity giữa tập ngoại lai). Đánh giá tác động của việc loại bỏ ngoại lai đến phân phối bằng kiểm định KS.

- c) **Chuẩn hóa dữ liệu có kiểm định:** Áp dụng Min-Max, Z-score, Robust Scaling và Quantile Transform (uniform và normal output). Sau mỗi phương pháp, có thể sử dụng kiểm định **Levene's test** để đánh giá sự đồng nhất phương sai (homoscedasticity). Thử trực quan hóa phân phối bằng violin plot theo từng thuộc tính và đánh giá.

- d) **Mã hóa biến phân loại nâng cao:** Ngoài One-Hot và Ordinal encoding cơ bản, sinh viên phải cài đặt và so sánh thêm:

- **Target Encoding** (mean encoding) với cross-validation để tránh target leakage.
- **Binary Encoding** cho thuộc tính có nhiều giá trị (high-cardinality, > 20 giá trị).
- **Frequency Encoding.**

Với từng phương pháp, đo tỉ lệ phương sai giải thích (variance inflation factor) để phát hiện đa cộng tuyến mới phát sinh.

- e) **Lựa chọn và giảm chiều đặc trưng:** **[Bắt buộc]** Cài đặt và so sánh ba tầng:

- *Lọc thống kê:* ANOVA F-test (thuộc tính số), Chi-square test (thuộc tính phân loại), Mutual Information.
- *Lọc dựa trên mô hình:* Feature importance từ Random Forest và Gradient Boosting; Recursive Feature Elimination (RFE) với cross-validation.
- *Giảm chiều:* PCA; t-SNE để trực quan hóa; UMAP nếu tập dữ liệu lớn.

Với mỗi phương pháp lọc, có thể huấn luyện mô hình học máy trên tập đặc trưng được chọn và báo cáo **cross-validation F1-score** (5-fold). Vẽ biểu đồ so sánh hiệu năng theo số lượng đặc trưng.

- f) **[Nâng cao] Phát hiện và xử lý mất cân bằng lớp:** Áp dụng SMOTE, ADASYN và Random Under-sampling. Với mỗi chiến lược, huấn luyện và đánh giá mô hình trên tập test chưa tái cân bằng. Báo cáo Precision, Recall, F1-macro và AUC-ROC. Giải thích tại sao không được áp dụng resampling trước khi chia tập train/test. (Nếu tập dữ liệu có xuất hiện tình trạng mất cân bằng)

2.3. Phần 3: Tiền xử lý dữ liệu văn bản

Lưu ý

Nếu chọn Phần 3, sinh viên không cần thực hiện Phần 4.

2.3.1. Lựa chọn tập dữ liệu

Sinh viên chọn một tập dữ liệu văn bản có ít nhất **10.000 mẫu** và ít nhất **2 nhãn phân loại**. Một số tập dữ liệu gợi ý:

- [IMDB Dataset of 50K Movie Reviews](#)
- [News Articles](#) (phân loại chủ đề)
- [Twitter 15 and 16](#) (phát hiện tin đồn)
- [Amazon Product Reviews Dataset](#)

2.3.2. Phân tích thống kê văn bản (Text EDA)

[Bắt buộc] Trước khi tiền xử lý:

- Tính và vẽ phân phối **độ dài văn bản** (số từ, số ký tự) theo nhãn lớp. Kiểm định Mann-Whitney U test để xác định liệu các lớp có sự khác biệt đáng kể về độ dài không.
- Vẽ **word cloud** và bảng top-50 từ phổ biến nhất theo từng lớp. Tính **type-token ratio (TTR)** để đánh giá độ phong phú từ vựng.
- Phân tích **phân phối Zipf**: vẽ log-log plot của tần suất từ và kiểm tra mức độ tuân theo định luật Zipf.

2.3.3. Các kỹ thuật tiền xử lý và phân tích tác động

- Pipeline chuẩn hóa văn bản**: Cài đặt pipeline hoàn chỉnh gồm: chuyển về chữ thường, loại bỏ HTML/URL/mention/hashtag, loại bỏ ký tự đặc biệt và số (có điều kiện), chuẩn hóa khoảng trắng. Với mỗi bước, báo cáo **tỉ lệ từ vựng thay đổi** và tác động đến phân phối độ dài văn bản.
- So sánh chiến lược tokenization**: Cài đặt và so sánh **4 chiến lược**: word-level (NLTK, spaCy), sentence-level, character-level, và subword (BPE bằng thư viện `tokenizers` của HuggingFace). Với mỗi chiến lược, báo cáo: (i) kích thước từ vựng; (ii) tỉ lệ OOV (out-of-vocabulary) trên tập test; (iii) độ dài chuỗi token trung bình.
- Loại bỏ stop words và phân tích thông tin**: Loại bỏ stop words và so sánh: (i) kích thước từ vựng trước/sau; (ii) MI (Mutual Information) trung bình giữa từ và nhãn trước/sau; (iii) hiệu năng Naive Bayes trước/sau. **Thảo luận liệu việc loại bỏ stop words có luôn cải thiện kết quả không.**
- Stemming, Lemmatization và so sánh định lượng**: Cài đặt Porter Stemmer, Snowball Stemmer và WordNet Lemmatizer. Tính **collision rate** (tỉ lệ các từ khác nhau bị map về cùng một dạng gốc) cho mỗi phương pháp. Đánh giá tác động đến hiệu năng phân loại (Logistic Regression, 5-fold CV).

- e) **Vector hóa văn bản và phân tích không gian đặc trưng:** Cài đặt BoW, TF-IDF (n -gram với $n \in \{1, 2, 3\}$), và Word2Vec (huấn luyện trên tập dữ liệu). Với mỗi biểu diễn: (i) báo cáo số chiều và độ thưa (sparsity ratio); (ii) tính cosine similarity giữa các cặp văn bản cùng lớp và khác lớp; (iii) trực quan hóa t-SNE 2D tô màu theo nhãn. Đánh giá khả năng tách lớp bằng **silhouette score**.
- f) **[Nâng cao] Biểu diễn ngữ nghĩa bằng Sentence Transformer:** Sử dụng mô hình pretrained (ví dụ: `all-MiniLM-L6-v2` từ `sentence-transformers`). So sánh chất lượng phân cụm (K-Means, silhouette score) và hiệu năng phân loại (Linear SVM) giữa TF-IDF và Sentence Transformer embeddings. Giải thích sự khác biệt về mặt ngữ nghĩa.

2.4. Phần 4: Tiền xử lý dữ liệu chuỗi thời gian

Lưu ý

Nếu chọn Phần 4, sinh viên không cần thực hiện Phần 3.

2.4.1. Lựa chọn tập dữ liệu

Mỗi nhóm chọn một tập dữ liệu chuỗi thời gian trải dài **ít nhất 2 năm** với **tần suất cao** (ngày hoặc giờ). Một số tập dữ liệu gợi ý:

- [Stock Market Data \(NASDAQ, NYSE, S&P500\)](#)
- [Dữ liệu thời tiết và khí hậu](#) (giờ hoặc ngày)
- [Dữ liệu tiêu thụ năng lượng](#)
- [Dữ liệu chuỗi thời gian COVID-19](#)

2.4.2. Phân tích khám phá chuỗi thời gian

[Bắt buộc] Sinh viên phải thực hiện phân tích ban đầu trước khi tiền xử lý:

- Vẽ **time plot** và xác định bằng mắt các thành phần: xu hướng (trend), mùa vụ (seasonality), nhiễu (noise).
- Vẽ **ACF** (Autocorrelation Function) và **PACF** (Partial ACF) với lag tối đa cụ thể, ví dụ: $\min(10 \log_{10} n, n/5)$ (với n là số khoảng thời gian) và nhận xét cấu trúc tương quan.
- Tính **rolling statistics**: trung bình trượt và độ lệch chuẩn với cửa sổ trượt 7, 30 và 90 ngày (hoặc tương đương). Có thể trực quan hóa và nhận xét tính dừng sơ bộ.

2.4.3. Các kỹ thuật tiền xử lý nâng cao

- a) **Xử lý khoảng trống và nội suy so sánh:** Tạo nhân tạo 5% khoảng trống thời gian (MCAR). Áp dụng 4 phương pháp: forward fill, linear interpolation, polynomial (ví dụ: đa thức bậc 2 và 3) interpolation, spline interpolation (cubic). Với mỗi phương pháp, tính **MAE** và **RMSE** **điền khuyết** và kiểm định **Ljung-Box test** để kiểm tra liệu phần dư sau điền khuyết có tự tương quan không.
- b) **Kiểm định tính dừng (Stationarity Tests):** **[Bắt buộc]** Áp dụng **ADF test** (Augmented Dickey-Fuller), **KPSS test** và **PP test** (Phillips-Perron) cho chuỗi gốc. Báo cáo p -value và kết luận. Nếu chuỗi không dừng, áp dụng các biến đổi: differencing bậc 1 và 2, logarithm, Box-Cox. Kiểm định lại sau mỗi biến đổi cho đến khi đạt tính dừng.
- c) **Phân rã chuỗi thời gian:** Áp dụng phân rã **Additive** và **Multiplicative** (thư viện `statsmodels`). Áp dụng **STL decomposition** (Seasonal-Trend decomposition using LOESS) với chu kỳ mùa vụ phù hợp. Đánh giá chất lượng phân rã bằng tỉ lệ phương sai của phần dư (residual variance ratio). Lấy phần *deseasonalized* và *detrended* để làm nền cho các bước tiếp theo.
- d) **Trích xuất đặc trưng thời gian:** Trích xuất và mã hóa: (i) đặc trưng chu kỳ bằng $\sin/\cos$ ($\sin(2\pi t/T)$ và $\cos(2\pi t/T)$) cho ngày trong tuần, tháng trong năm; (ii) ngày lễ và sự kiện đặc biệt (dùng thư viện `holidays`); (iii) đặc trưng thống kê cửa sổ trượt (mean, std, min, max, skewness) với nhiều tỉ lệ cửa sổ trượt khác nhau.
- e) **Phát hiện dị thường (bất thường) trong chuỗi thời gian:** **[Bắt buộc]** Cài đặt và so sánh 3 phương pháp: (i) phương pháp thống kê (Z-score trên chuỗi đã *deseasonalize*); (ii) **Isolation Forest** trên cửa sổ trượt; (iii) phương pháp dựa trên tái tạo (Autoencoder 1D hoặc STL residual thresholding). Đánh dấu các điểm dị thường trên biểu đồ thời gian và thảo luận nguyên nhân có thể.
- f) **Xây dựng ma trận đặc trưng cho dự báo:** **[Bắt buộc]** Xây dựng ma trận đặc trưng đầy đủ gồm: (i) lag features $t-1, t-2, \dots, t-p$ với p được xác định từ PACF; (ii) rolling statistics với nhiều tỉ lệ; (iii) đặc trưng thời gian; (iv) chuỗi đã phân rã. Huấn luyện một mô hình **Random Forest Regressor** để dự báo $t+1$ và báo cáo MAE, RMSE trên tập test. Sử dụng kết quả này như bằng chứng định lượng cho chất lượng tiền xử lý.
- g) **[Nâng cao] Phân tích nhân quả Granger (Granger Causality):** Với tập dữ liệu có nhiều biến (multivariate), áp dụng Granger causality test để kiểm tra liệu biến X có *Granger-cause* biến Y không. Lập bảng ma trận nhân quả và trực quan hóa bằng đồ thị có hướng (directed graph).

3. YÊU CẦU TRIỂN KHAI

3.1. Yêu cầu kỹ thuật

- Toàn bộ cài đặt bằng **Python** và sử dụng **Jupyter Notebooks** để minh họa kết quả.

- Thư viện được phép sử dụng: `numpy`, `pandas`, `matplotlib`, `seaborn`, `scikit-learn`, `scipy`, `statsmodels`, `opencv-python` / `Pillow` (ảnh), `nltk` / `spacy` (văn bản), `missingno`, `imbalanced-learn`.
- Tất cả kết quả số (score, p -value, ...) phải được in ra và đặt trong biến Python để dễ kiểm tra lại.
- **Mỗi kỹ thuật tiền xử lý** phải có: (i) ô markdown giải thích lý thuyết và công thức toán (nếu có); (ii) ô code cài đặt; (iii) ô markdown phân tích kết quả.

3.2. Yêu cầu báo cáo PDF

Ngoài notebook, nhóm phải nộp một **báo cáo PDF riêng biệt** (tối thiểu 20 trang) gồm:

1. **Tóm tắt điều hành** (1 trang): Tóm tắt các phát hiện chính và kết luận quan trọng nhất từ mỗi phần.
2. **Phân tích so sánh**: Bảng tổng hợp so sánh tất cả kỹ thuật trong mỗi phần với chỉ số định lượng cụ thể.
3. **Thảo luận và nhận xét**: Mỗi phần phải có ít nhất **một đoạn văn thảo luận** về lý do lựa chọn cuối cùng, hạn chế và hướng cải tiến.
4. **Phân công công việc**: Bảng rõ ràng về phân công và đóng góp của từng thành viên.
5. **Ngôn ngữ**: Toàn bộ báo cáo viết bằng **tiếng Việt**. Thuật ngữ kỹ thuật tiếng Anh giữ nguyên trong ngoặc đơn lần đầu xuất hiện.

4. TỔ CHỨC ĐỒ ÁN

Cấu trúc thư mục bắt:

Sinh viên có thể tham khảo cấu trúc đồ án này hoặc tự đề xuất cấu trúc khác, nhưng phải đảm bảo dễ hiểu và rõ ràng:

```
Group_ID/  
|-- README.md # Tổng quan, hướng dẫn chạy, link tài nguyên  
|-- requirements.txt # Version cụ thể của toàn bộ thư viện  
|-- data/  
|   |-- raw/ # Dữ liệu gốc (hoặc link Google Drive)  
|   |-- processed/ # Dữ liệu sau tiền xử lý  
|-- notebooks/  
|   |-- 01_EDA_image.ipynb  
|   |-- 02_preprocessing_image.ipynb  
|   |-- 03_EDA_tabular.ipynb  
|   |-- 04_preprocessing_tabular.ipynb  
|   |-- 05_text_preprocessing.ipynb # Nếu chọn Phần 3
```

```
| | -- 06_temporal_preprocessing.ipynb # Neu chon Phan 4
| -- docs/
| | -- Report.pdf # Bao cao PDF bat buoc
```

5. TIÊU CHÍ CHẤM ĐIỂM

STT	Tiêu chí	Điểm
1	Phần 1 – Tiền xử lý ảnh (Bắt buộc)	25%
	Phân tích thống kê tập dữ liệu (pHash, class imbalance, KS test)	7%
	Cài đặt đúng kỹ thuật + đo lường SSIM/PSNR	10%
	Ablation study + phân tích PCA/t-SNE	8%
2	Phần 2 – Tiền xử lý dữ liệu bảng (Bắt buộc)	25%
	EDA thống kê (kiểm định phân phối, MCAR test)	7%
	Phát hiện ngoại lai + mã hóa đặc trưng đầu vào	10%
	Lựa chọn đặc trưng + đánh giá CV F1-score	8%
3	Phần 3 – Tiền xử lý văn bản	20%
	Text EDA + phân tích Zipf	5%
	Pipeline chuẩn hóa + so sánh tokenization (OOV rate)	8%
	Vector hóa + silhouette score + Sentence Transformer	7%
4	Phần 4 – Tiền xử lý chuỗi thời gian	20%
	Kiểm định tính dừng + phân rã STL	7%
	Phát hiện dị thường + xây dựng ma trận đặc trưng	8%
	Dự báo RF Regressor + Granger causality	5%
5	Chất lượng mã nguồn và báo cáo	30%
	Mã sạch, có chú thích, tái sản xuất được ($AI \leq 30\%$)	10%
	Cấu trúc thư mục, README đầy đủ	5%
	Báo cáo PDF: phân tích so sánh, thảo luận, phân công rõ ràng	15%
Điểm cộng/ thưởng		10%
Tổng: (1) + (2) + (5) + (3 HOẶC 4)		110%

Rubric chấm điểm chi tiết:

- **Xuất sắc** (90–100% điểm phần): Kết quả đúng, phân tích sâu, diễn giải thống kê chặt chẽ, có nhận xét phê bình.
- **Tốt** (70–89%): Kết quả đúng/ hợp lý, có phân tích nhưng thiếu chiều sâu hoặc kiểm định thống kê.
- **Đạt** (50–69%): Cài đặt đúng nhưng thiếu phân tích hoặc so sánh. Lập luận còn chưa thuyết phục.

- **Chưa đạt (< 50%):** Áp dụng kỹ thuật không phù hợp, thiếu nhiều yêu cầu, notebook không chạy được, trình bày ẩu/ khó hiểu.

Lưu ý khác:

- **Liên chính học thuật:** Mọi hình thức đạo văn, gian lận, thiếu trung thực hoặc hợp tác trái phép đều dẫn đến điểm 0 cho toàn bộ môn học.
- **Sử dụng công cụ AI:** Được phép với mức độ vừa phải tối đa 30%, sinh viên cần đảm bảo hiểu những gì mà bản thân/ nhóm đang thực hiện.
- **Đảm bảo Jupyter Notebook chạy được:** Restart & Run All trước khi nộp. Notebook lỗi runtime tương ứng phần nào sẽ không được chấm phần đó.
- **Chính sách nộp trễ:** Không chấp nhận nộp trễ dưới mọi hình thức.
- **Dời deadline:** Phụ thuộc vào giảng viên.

6. NỘP BÀI

- **Định dạng:** File nén .zip tên Group_ID.zip (ví dụ: Group_05.zip).
- **File lớn:** Nếu vượt 25MB, giữ lại báo cáo và mã nguồn; tải dữ liệu lên Google Drive và cung cấp link công khai trong README.
- **Notebook phải sạch:** Trước khi nộp, *Restart Kernel & Run All* toàn bộ notebook. Notebook có lỗi runtime sẽ **không được chấm** phần tương ứng.
- **README bắt buộc** gồm: tên và MSSV thành viên; mô tả tập dữ liệu; hướng dẫn cài đặt môi trường và chạy notebook; bảng phân công công việc; link tài nguyên ngoài.