

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỒ ÁN 1
TIỀN XỬ LÝ DỮ LIỆU

Phân tích thống kê – Thiết kế Pipeline – Phân tích & Đánh giá tác động

Môn học: CSC14004 – Khai thác dữ liệu và ứng dụng

Học kỳ: Học kỳ 2 – 2025/2026

GV Thực hành: ThS Nguyễn Thị Thu Hằng
ThS Nguyễn Ngọc Đức
ThS Lê Nhật Nam

Nhóm sinh viên thực hiện:

- | | |
|-----------------------|----------------|
| 1. Nguyễn Lâm Phú Quý | MSSV: 23122048 |
| 2. Phạm Phú Hòa | MSSV: 23122030 |
| 3. Trần Chí Nguyên | MSSV: 23122044 |
| 4. Đào Sỹ Duy Minh | MSSV: 23122041 |

Tp. Hồ Chí Minh, tháng 4 năm 2026

Tóm tắt nội dung

Báo cáo này trình bày toàn bộ quy trình tiền xử lý dữ liệu trên ba loại dữ liệu khác nhau theo yêu cầu của Đồ án 1 môn Khai thác dữ liệu và ứng dụng (CSC14004). **Phần 1** xử lý dữ liệu ảnh – tập NWPU-RESISC45 (31.500 ảnh, 45 lớp) – bao gồm phân tích thống kê mô tả (phân phối pixel, phát hiện ảnh trùng lặp bằng pHash, kiểm định Kruskal-Wallis), thiết kế pipeline ablation cho resize/color-space/normalization/augmentation, và phân tích nâng cao bằng PCA + phát hiện cạnh. **Phần 2** xử lý dữ liệu dạng bảng – tập IEEE-CIS Fraud Detection (≈ 590.000 dòng, ≈ 400 cột) – với EDA chuyên sâu, so sánh 7 chiến lược điền khuyết, 5 phương pháp phát hiện ngoại lai, 5 phương pháp chuẩn hóa, 5 phương pháp mã hóa phân loại, và 3 tầng lựa chọn đặc trưng. **Phần 3** (thay thế Phần 4) xử lý dữ liệu văn bản – tập RAGTruth (≈ 18.000 mẫu, nhãn phát hiện hallucination) – bao gồm Text EDA (phân phối Zipf, Mann-Whitney), pipeline chuẩn hóa 9 bước, so sánh 4 chiến lược tokenization, phân tích stop words/stemming/lemmatization, và vector hóa (BoW/TF-IDF/Word2Vec/Sentence Transformer). Mọi kỹ thuật đều được đánh giá định lượng thông qua kiểm định thống kê phù hợp và ablation study.

Từ khóa: Tiền xử lý dữ liệu, NWPU-RESISC45, IEEE-CIS Fraud Detection, RAGTruth, PCA, TF-IDF, Sentence Transformer, Ablation Study, Kiểm định thống kê.

Mục lục

1	THÔNG TIN NHÓM VÀ PHÂN CÔNG CÔNG VIỆC	5
1.1	Thông tin các thành viên	5
1.2	Phân công công việc chi tiết	6
2	TÓM TẮT ĐIỀU HÀNH	6
3	PHẦN 1: TIỀN XỬ LÝ DỮ LIỆU ẢNH SỐ	7
3.1	Mô tả tập dữ liệu	7
3.2	Phân tích thống kê tập dữ liệu (EDA)	8
3.2.1	Phân phối giá trị pixel	8
3.2.2	Phân tích cân bằng lớp (Class Imbalance)	8
3.2.3	Phát hiện ảnh trùng lặp (Duplicate Detection)	9
3.2.4	Phân tích độ sáng và độ tương phản	9
3.3	Các kỹ thuật tiền xử lý và phân tích tác động	9
3.3.1	Thay đổi kích thước ảnh (Resize Ablation)	9
3.3.2	Chuyển đổi không gian màu (Color Space Ablation)	10
3.3.3	Chuẩn hóa dữ liệu (Normalization Ablation)	10
3.3.4	Tăng cường dữ liệu (Data Augmentation)	10
3.4	Phân tích nâng cao	11
3.4.1	Phân tích PCA trên không gian đặc trưng ảnh	11
3.4.2	Phát hiện cạnh và phân tích đặc trưng cục bộ	11
4	PHẦN 2: TIỀN XỬ LÝ DỮ LIỆU DẠNG BẢNG	12
4.1	Mô tả tập dữ liệu	12
4.2	Phân tích thống kê khám phá (EDA)	12
4.2.1	Kiểm tra phân phối (Normality Tests)	12
4.2.2	Phân tích tương quan đa biến	13
4.2.3	Phân tích giá trị thiếu	13
4.3	Các kỹ thuật tiền xử lý và đánh giá định lượng	13
4.3.1	Xử lý giá trị thiếu (Imputation)	13
4.3.2	Phát hiện và xử lý ngoại lai (Outlier Detection)	14
4.3.3	Chuẩn hóa dữ liệu (Scaling)	14
4.3.4	Mã hóa biến phân loại (Categorical Encoding)	15
4.3.5	Lựa chọn và giảm chiều đặc trưng (Feature Selection)	15
4.3.6	Xử lý mất cân bằng lớp (Class Imbalance)	16
5	PHẦN 3: TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN	16
5.1	Mô tả tập dữ liệu	16
5.2	Phân tích thống kê văn bản (Text EDA)	17

5.2.1	Phân phối độ dài văn bản	17
5.2.2	Word Cloud và Type-Token Ratio	17
5.2.3	Phân tích phân phối Zipf	17
5.3	Các kỹ thuật tiền xử lý và phân tích tác động	17
5.3.1	Pipeline chuẩn hóa văn bản (9 bước)	18
5.3.2	So sánh chiến lược Tokenization	18
5.3.3	Loại bỏ Stop Words và Phân tích thông tin	18
5.3.4	Stemming, Lemmatization và So sánh định lượng	19
5.3.5	Vector hóa văn bản (Vectorization)	19
5.3.6	[Nâng cao] Biểu diễn ngữ nghĩa bằng Sentence Transformer	20
5.4	Bảng xếp hạng phân loại cuối cùng	20
6	PHÂN TÍCH SO SÁNH TỔNG HỢP	21
6.1	Tổng hợp lựa chọn pipeline	21
6.2	Thảo luận	21
7	KẾT LUẬN	22
	TÀI LIỆU THAM KHẢO	22

Danh sách bảng

1	Thông tin các thành viên nhóm	5
2	Bảng phân công công việc chi tiết	6
3	Thông tin tập dữ liệu NWPU-RESISC45	8
4	Kết quả ANOVA cho brightness và contrast theo lớp	9
5	So sánh các không gian màu theo PCA variance và k-NN accuracy	10
6	Phân tích Edge Density theo lớp	12
7	Thông tin tập dữ liệu IEEE-CIS Fraud Detection	12
8	Tỉ lệ giá trị thiếu theo nhóm đặc trưng	13
9	Các chiến lược điền khuyết được so sánh	14
10	So sánh 5 phương pháp phát hiện ngoại lai	14
11	So sánh 5 phương pháp chuẩn hóa	15
12	So sánh các chiến lược xử lý mất cân bằng lớp (kết quả tính tại runtime)	16
13	Thông tin tập dữ liệu RAGTruth	17
14	Pipeline chuẩn hóa văn bản 9 bước	18
15	So sánh 4 chiến lược tokenization (kết quả tính tại runtime)	18
16	So sánh stemming và lemmatization (kết quả runtime)	19
17	So sánh các phương pháp vector hóa văn bản (kết quả runtime)	20
18	Bảng xếp hạng phân loại cuối cùng trên RAGTruth	20
19	Tổng hợp các lựa chọn pipeline cuối cùng	21

1 THÔNG TIN NHÓM VÀ PHÂN CÔNG CÔNG VIỆC

1.1 Thông tin các thành viên

MSSV	Họ và Tên	Email	Vai trò
23122048	Nguyễn Lâm Phú Quý	23122048@student.hcmus.edu.vn	Nhóm trưởng
23122041	Đào Sỹ Duy Minh	23122041@student.hcmus.edu.vn	Thành viên
23122030	Phạm Phú Hòa	23122030@student.hcmus.edu.vn	Thành viên
23122044	Trần Chí Nguyên	23122044@student.hcmus.edu.vn	Thành viên

Bảng 1: Thông tin các thành viên nhóm

1.2 Phân công công việc chi tiết

Thành viên	Công việc được giao	Hoàn thành
Nguyễn Lâm Phú Quý	- Phần 1: EDA ảnh (notebook 01), pipeline pre-processing ảnh (notebook 02) - Thiết kế ablation study resize/color-space - Viết báo cáo Phần 1 và Tóm tắt điều hành - Tích hợp và format báo cáo cuối	100%
Phạm Phú Hòa	- Phần 1 nâng cao: PCA, phát hiện cạnh (notebook 03) - Phần 2: EDA dữ liệu bảng, xử lý giá trị thiếu (notebook 04) - Viết báo cáo Phần 2 mục EDA và imputation - Chạy thực nghiệm và đo performance	100%
Đào Sỹ Duy Minh	- Phần 2: Phát hiện ngoại lai, chuẩn hóa, mã hóa phân loại (notebook 04) - Viết báo cáo Phần 2 mục outlier, scaling, encoding - Xây dựng bảng so sánh định lượng - Review và testing toàn bộ code	100%
Trần Chí Nguyên	- Phần 2: Lựa chọn đặc trưng, xử lý mất cân bằng lớp (notebook 04) - Phần 3: Toàn bộ Text preprocessing (notebook 05) - Viết báo cáo Phần 3 - Hoàn thiện báo cáo, formatting LaTeX	100%

Bảng 2: Bảng phân công công việc chi tiết

Ghi chú: Mọi thành viên đều tham gia thảo luận, review code và hoàn thiện báo cáo. Phân công trên chỉ mang tính chính yếu, không loại trừ sự hỗ trợ lẫn nhau.

2 TÓM TẮT ĐIỀU HÀNH

Đồ án này xử lý ba loại dữ liệu: ảnh số, bảng và văn bản. Dưới đây là các phát hiện và kết luận quan trọng nhất từ mỗi phần.

Phần 1 – Ảnh (NWPU-RESISC45):

- Tập dữ liệu hoàn toàn cân bằng (600 train / 100 test mỗi lớp), tỉ lệ ảnh trùng lặp rất thấp (0,05%).

- Kiểm định Kruskal-Wallis với hiệu ứng η^2 lớn ($R=0,500$; $G=0,437$; $B=0,455$) xác nhận các lớp có phân phối pixel khác biệt có ý nghĩa thống kê.
- Độ tương phản (contrast) có sức phân biệt lớp cao nhất ($\eta^2 = 0,492$, $F = 48,62$).
- Kích thước 128×128 được chọn là tối ưu (cân bằng giữa SSIM và chi phí tính toán).
- Không gian màu HSV cho k-NN accuracy cao nhất; LAB cho phương sai PCA giải thích cao nhất.
- Augmentation làm tăng đáng kể phương sai trong lớp (Wilcoxon $p < 0,05$).

Phần 2 – Dữ liệu bảng (IEEE-CIS Fraud):

- 399/400 cột không tuân phân phối chuẩn (D’Agostino-Pearson $p \leq 0,05$).
- Tỷ lệ mất cân bằng lớp cao: fraud $\approx 3,5\%$ (ratio 28:1).
- Nhóm Identity có tỷ lệ missing cao nhất (84,5%), cơ chế chủ yếu là MAR/MNAR.
- Median imputation được chọn làm chiến lược sản xuất (MICE OverMemory với >400 cột).
- RobustScaler là phương pháp chuẩn hóa tốt nhất do sự không chuẩn và outlier còn tồn tại.
- Feature selection: union top-20 RF + GB features cho kết quả tốt nhất.

Phần 3 – Văn bản (RAGTruth):

- Luật Zipf được tuân theo với $\alpha \approx 1,63$ (lệch khỏi $\alpha = 1,0$ lý tưởng).
- Loại bỏ stop words không luôn cải thiện kết quả phân loại (Wilcoxon p có thể $> 0,05$).
- WordNet Lemmatizer bảo toàn ngữ nghĩa tốt nhất (collision rate thấp nhất).
- TF-IDF bigram + Logistic Regression cho F1-macro cao nhất trên 5-fold CV.
- Sentence Transformer không vượt trội TF-IDF trong task phát hiện hallucination.

3 PHẦN 1: TIỀN XỬ LÝ DỮ LIỆU ẢNH SỐ

3.1 Mô tả tập dữ liệu

Tập dữ liệu được sử dụng là **NWPU-RESISC45** (Northwestern Polytechnical University Remote Sensing Image Scene Classification), một tập dữ liệu ảnh viễn thám tiêu chuẩn được sử dụng rộng rãi trong nghiên cứu phân loại cảnh quan.

Thuộc tính	Giá trị
Tổng số ảnh	31.500 (27.000 train + 4.500 test)
Số lớp	45 (airplane, airport, beach, forest, harbor, ...)
Ảnh mỗi lớp	600 train / 100 test (hoàn toàn cân bằng)
Độ phân giải	256×256 pixels
Định dạng	JPEG, RGB, 3 kênh màu
Nguồn	Kaggle

Bảng 3: Thông tin tập dữ liệu NWPU-RESISC45

3.2 Phân tích thống kê tập dữ liệu (EDA)

3.2.1 Phân phối giá trị pixel

Phân phối giá trị pixel được tính toán theo từng kênh màu (R, G, B) trên toàn tập huấn luyện, với histogram và KDE overlay cho 5 lớp đại diện (airplane, beach, forest, desert, chaparral).

Kết quả:

- Giá trị trung bình pixel toàn tập: $R = 93,8$; $G = 97,1$; $B = 87,6$.
- Phân phối nghiêng phải (right-skewed): mean > median khoảng 4 đơn vị trên cả 3 kênh.

Kiểm định Levene (phương sai đồng nhất): $p \approx 0 \Rightarrow$ phương sai các lớp không đồng nhất $\Rightarrow$ sử dụng kiểm định **Kruskal-Wallis** (phi tham số) thay vì ANOVA.

Kết quả Kruskal-Wallis (3 kênh màu, $p \approx 0$): bác bỏ H_0 – các lớp có phân phối pixel khác biệt có ý nghĩa thống kê. **Effect size** η^2 : $R = 0,500$; $G = 0,437$; $B = 0,455$ (đều thuộc mức "large" theo Cohen).

Kiểm định post-hoc Mann-Whitney với hiệu chỉnh Bonferroni ($\alpha = 0,005$): đa số cặp lớp có $p \ll 0,005$; ngoại lệ: cặp freeway – river tại kênh R ($p = 0,45$).

3.2.2 Phân tích cân bằng lớp (Class Imbalance)

- Kiểm định Chi-square: $\chi^2 = 0$ (mỗi lớp đúng 600 ảnh) $\Rightarrow$ **tập dữ liệu hoàn toàn cân bằng**.
- Imbalance ratio = 1,00 – không cần áp dụng kỹ thuật resampling cho dữ liệu ảnh.

3.2.3 Phát hiện ảnh trùng lặp (Duplicate Detection)

Sử dụng **Perceptual Hash (pHash)** dựa trên biến đổi DCT 64-bit và khoảng cách Hamming để xác định ảnh trùng hoặc gần trùng (ngưỡng Hamming ≤ 4 bit).

Kết quả:

- **Ảnh trùng lặp hoàn toàn:** 7 nhóm / 14 ảnh (0,05% tổng tập), tập trung ở lớp airport.
- **Ảnh gần trùng** (Hamming ≤ 4): quét trong cùng lớp (≈ 8 triệu cặp so sánh).
- Tỷ lệ trùng lặp thấp – không ảnh hưởng đáng kể đến chất lượng huấn luyện.

3.2.4 Phân tích độ sáng và độ tương phản

Chuyển sang không gian màu **CIE Lab**; kênh L đại diện cho độ sáng (luminance). Tính:

- **Brightness** = mean(L) theo từng lớp.
- **Contrast** = std(L) theo từng lớp.

Kết quả ANOVA một chiều:

Chỉ số	F-statistic	p-value	η^2
Brightness (mean L)	38,37	≈ 0	0,434
Contrast (std L)	48,62	≈ 0	0,492

Bảng 4: Kết quả ANOVA cho brightness và contrast theo lớp

Nhận xét: Contrast có sức phân biệt lớp cao nhất ($\eta^2 = 0,492$) trong số tất cả các chỉ số được phân tích.

3.3 Các kỹ thuật tiền xử lý và phân tích tác động

3.3.1 Thay đổi kích thước ảnh (Resize Ablation)

Resize về các kích thước 64×64 , 128×128 , 224×224 , 256×256 (gốc). Với mỗi kích thước, tính:

- **SSIM** (Structural Similarity Index): đo mức độ giống nhau về cấu trúc so với ảnh gốc.
- **PSNR** (Peak Signal-to-Noise Ratio): $\text{PSNR} = 10 \cdot \log_{10} \left(\frac{255^2}{\text{MSE}} \right)$ (dB).
- Độ chính xác k-NN (5-fold cross-validation) trên pixel features.

Kết luận: Kích thước **128×128** được chọn là tối ưu – đạt cân bằng tốt giữa SSIM cao và chi phí tính toán chấp nhận được. ANOVA trên phân phối SSIM giữa các kích thước:

$p < 0,05$.

3.3.2 Chuyển đổi không gian màu (Color Space Ablation)

So sánh 4 không gian màu: **RGB, Grayscale, HSV, CIE Lab**. Với mỗi không gian màu:

- PCA explained variance với $k = 50$ thành phần (mẫu 500 ảnh).
- Độ chính xác k-NN 5-fold CV trên pixel features.

Không gian màu	PCA Explained Var. (50 PC)	k-NN Accuracy
RGB	Trung bình	Trung bình (baseline)
Grayscale	Thấp nhất	Thấp nhất
HSV	Cao	Cao nhất
CIE Lab	Cao nhất	Cao

Bảng 5: So sánh các không gian màu theo PCA variance và k-NN accuracy

Nhận xét: HSV cải thiện k-NN accuracy do tách biệt thông tin sắc độ (H) khỏi độ sáng (V); LAB giữ thông tin tốt nhất cho PCA. RGB được chọn làm baseline cho pipeline.

3.3.3 Chuẩn hóa dữ liệu (Normalization Ablation)

Cài đặt và so sánh 4 phương pháp chuẩn hóa:

1. **Min-Max [0,1]:** $x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$
2. **Min-Max [-1,1]:** $x' = 2 \cdot \frac{x - x_{\min}}{x_{\max} - x_{\min}} - 1$
3. **Z-score toàn tập:** $x' = \frac{x - \mu}{\sigma}$
4. **Z-score per-channel:** chuẩn hóa độc lập trên từng kênh R, G, B.

Kiểm định Kolmogorov-Smirnov (KS test): $D = \sup |F_1(x) - F_2(x)|$ so sánh phân phối trước và sau mỗi phương pháp. $p \approx 0$ cho tất cả phương pháp (kỳ vọng – đây là shift phân phối mong muốn). **Kiểm định Wilcoxon signed-rank** so sánh hai phương pháp tốt nhất; Cohen's d đo kích thước hiệu ứng.

Kết quả lựa chọn pipeline: Z-score per-channel thường được chọn (kiểm soát tốt hơn sự chênh lệch giữa các kênh).

3.3.4 Tăng cường dữ liệu (Data Augmentation)

Cài đặt pipeline augmentation gồm **6 phép biến đổi**:

- Lật ngang (Horizontal Flip), Lật dọc (Vertical Flip)

- Xoay ngẫu nhiên $\pm 15^\circ$
- Cắt ngẫu nhiên (Random Crop, scale=0,8)
- Thêm nhiễu Gaussian ($\sigma = 25$)
- Điều chỉnh độ sáng/tương phản ± 20

Phân tích tác động:

- Ablation từng kỹ thuật: 30 ảnh/lớp $\times$ 45 lớp, so sánh k-NN accuracy trước/sau.
- **Kiểm định Wilcoxon signed-rank**: $p < 0,05$ – augmentation làm tăng đáng kể phương sai trong lớp (intra-class variance). Đây là hành vi kỳ vọng: raw-pixel k-NN không bất biến với phép xoay/lật; mô hình CNN sẽ hưởng lợi từ augmentation.
- **t-SNE visualization**: so sánh phân phối đặc trưng tập gốc vs. tập đã augment (9 mức số lượng class, perplexity=30).

3.4 Phân tích nâng cao

3.4.1 Phân tích PCA trên không gian đặc trưng ảnh

Áp dụng **IncrementalPCA** (batch_size=500, n_components=200) trên 27.000 ảnh grayscale 64×64 (mà trận 27.000×4.096 , chiếm ≈ 440 MB).

Kết quả:

- Số thành phần để giải thích 90%, 95%, 99% phương sai: tính động tại runtime.
- Kiểm định Kruskal-Wallis trên PC1: $p \approx 0$, η^2 lớn – các lớp có thể phân biệt trên thành phần chính đầu tiên.
- Eigenimage PC1 mã hóa độ sáng tổng thể; PC2, PC3 mã hóa cấu trúc cạnh/texture.
- ARI (Adjusted Rand Index) trên PCA 2D với 45 lớp: thấp – xác nhận cần giảm chiều phi tuyến.
- t-SNE 2D (5.000 ảnh mẫu, 50 PC pre-reduction, perplexity=30): hiển thị rõ hơn sự phân tách lớp.

3.4.2 Phát hiện cạnh và phân tích đặc trưng cục bộ

So sánh 3 bộ phát hiện cạnh: **Sobel**, **Prewitt**, **Canny** với ≥ 2 bộ siêu tham số mỗi loại. Tính **Edge Density** = tỉ lệ pixel cạnh / tổng pixel theo từng lớp.

Tìm kiếm siêu tham số: Ngưỡng $T \in \{30, 50, 80, 120\}$ cho Sobel/Prewitt; hai cấu hình Canny ($\sigma = 1,0/2,0$, $T_1 = 50/100$, $T_2 = 150/200$). Ngưỡng tốt nhất được chọn bởi η^2 cao nhất.

Kiểm định ANOVA/Kruskal-Wallis trên Edge Density: $p \approx 0$ – thông tin cạnh có khả năng phân biệt các lớp.

Edge Density cao nhất	dense_residential, chaparral (ảnh đô thị/vegetation giàu texture)
Edge Density thấp nhất	island, runway, sea_ice (bề mặt đồng nhất)
Tương quan Sobel–Canny	Tương quan cao (per-class means); Canny nhạy hơn với T_1/T_2 .

Bảng 6: Phân tích Edge Density theo lớp

4 PHẦN 2: TIỀN XỬ LÝ DỮ LIỆU DẠNG BẢNG

4.1 Mô tả tập dữ liệu

Tập dữ liệu được sử dụng là **IEEE-CIS Fraud Detection** (Kaggle), bao gồm dữ liệu giao dịch thương mại điện tử dùng cho bài toán phát hiện gian lận.

Thuộc tính	Giá trị
Kích thước train	≈ 590.000 dòng $\times \approx 400$ cột
Kích thước test	≈ 500.000 dòng
Biến mục tiêu	isFraud (nhị phân: 0 = Bình thường, 1 = Gian lận)
Tỉ lệ gian lận	$\approx 3,5\%$ (mất cân bằng cực cao)
Nhóm đặc trưng	Transaction, Card (card1–6), Address/Dist, Email, C-count (C1–C14), D-timedelta (D1–D15), M-match (M1–M9), V-Vesta (V1–V339), Identity (≈ 40 cột)
Nguồn	Kaggle – IEEE-CIS Fraud Detection Challenge

Bảng 7: Thông tin tập dữ liệu IEEE-CIS Fraud Detection

4.2 Phân tích thống kê khám phá (EDA)

4.2.1 Kiểm tra phân phối (Normality Tests)

Vì $n > 5000$, sử dụng kiểm định **D’Agostino-Pearson** ($K^2 = Z_1^2 + Z_2^2$, phân phối $\chi^2(2)$) trên mẫu $n = 20.000$.

Kết quả:

- **399/400** cột không tuân phân phối chuẩn ($p \leq 0,05$).
- Chỉ **id_25** tuân phân phối chuẩn ($p = 0,627$).
- Ví dụ: **TransactionAmt**: $K^2 = 25.679$, $p \approx 0$ (phân phối log-normal cực kỳ lệch phải).
- **Hệ quả**: Chọn phương pháp chuẩn hóa robust (không giả định chuẩn) cho pipeline.

4.2.2 Phân tích tương quan đa biến

Vẽ heatmap tương quan Pearson và Spearman (top-30 cột ít missing nhất). Xác định các cặp cột có $|r| > 0,9$ (đa cộng tuyến mạnh) và đề xuất xử lý (loại bỏ hoặc kết hợp).

4.2.3 Phân tích giá trị thiếu

Trực quan hóa missing data matrix bằng thư viện `missingno`. **Kiểm định Little's MCAR test** (gần đúng bằng χ^2).

Nhóm đặc trưng	Tỉ lệ missing	Cơ chế
Identity (id_01–id_38, DeviceType, DeviceInfo)	84,5%	MAR/MNAR
D-timedelta (D1–D15)	58,2%	MAR/MNAR
M-match (M1–M9)	49,9%	MAR/MNAR
Email (P_emaildomain, R_emaildomain)	46,4%	MAR/MNAR
V-Vesta (V1–V339)	43,0%	MAR/MNAR
Card (card1–card6)	0,5%	MCAR
Transaction, C-count	0%	—

Bảng 8: Tỉ lệ giá trị thiếu theo nhóm đặc trưng

Bằng chứng MAR/MNAR: $> 30\%$ tổng số cột có $|\text{corr}(\text{missing indicator}, \text{isFraud})| > 0,05$.

4.3 Các kỹ thuật tiền xử lý và đánh giá định lượng

4.3.1 Xử lý giá trị thiếu (Imputation)

Cài đặt và so sánh **7 chiến lược điền khuyết**. Benchmark: tạo nhân tạo 10% MCAR trên $15 \text{ cột} \times 5.000 \text{ dòng}$, tính RMSE.

Chiến lược	Mô tả
Mean	Điền bằng giá trị trung bình cột
Median	Điền bằng giá trị trung vị cột
Mode	Điền bằng giá trị phổ biến nhất
kNN-3	k láng giềng gần nhất, $k = 3$
kNN-5	k láng giềng gần nhất, $k = 5$
kNN-10	k láng giềng gần nhất, $k = 10$
MICE	Multiple Imputation by Chained Equations

Bảng 9: Các chiến lược điền khuyết được so sánh

Kiểm định thống kê: Friedman test + post-hoc pairwise Wilcoxon (Bonferroni correction).

Lựa chọn sản xuất: **Median imputation** – MICE có RMSE tốt hơn nhưng vượt quá bộ nhớ với > 400 cột; Median cho kết quả ổn định và hiệu quả.

4.3.2 Phát hiện và xử lý ngoại lai (Outlier Detection)

Cài đặt và so sánh **5 phương pháp** trên mẫu 10.000×20 cột:

Phương pháp	Tham số	Đặc điểm
IQR	factor = 1,5	Đơn giản, bền vững
Z-score	$ z > 3$	Giả định chuẩn
Isolation Forest	contamination $\in \{0,01; 0,05; 0,10\}$	Nhạy với high-dim
LOF	$k \in \{10; 20; 50\}$	Phát hiện local outlier
DBSCAN	eps=3,0; min_samples=5	Gom cụm ngoại lai

Bảng 10: So sánh 5 phương pháp phát hiện ngoại lai

Với mỗi phương pháp: báo cáo tỉ lệ phát hiện ngoại lai và **Jaccard similarity** giữa các tập ngoại lai. **KS 2-sample test** đánh giá tác động phân phối của việc loại bỏ ngoại lai ($D = \sup |F_1(x) - F_2(x)|$).

Lựa chọn sản xuất: **IQR clipping** (clip về $[Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]$) – bảo toàn số hàng, không xóa dữ liệu.

4.3.3 Chuẩn hóa dữ liệu (Scaling)

So sánh **5 phương pháp chuẩn hóa**:

Phương pháp	Công thức
Min-Max $[0,1]$	$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$
Z-score	$x' = \frac{x - \mu}{\sigma}$
Robust Scaling	$x' = \frac{x - Q_2}{Q_3 - Q_1}$
Quantile-Uniform	Ánh xạ về Uniform(0,1) qua CDF thực nghiệm
Quantile-Normal	Ánh xạ về $\mathcal{N}(0, 1)$ qua CDF thực nghiệm

Bảng 11: So sánh 5 phương pháp chuẩn hóa

Kiểm định Levene's test: $H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2$ (đồng nhất phương sai – homoscedasticity). Violin plot trực quan hóa phân phối sau chuẩn hóa.

Lựa chọn sản xuất: RobustScaler – bền vững với outlier còn tồn tại sau IQR clipping; phù hợp với 399/400 cột không chuẩn.

4.3.4 Mã hóa biến phân loại (Categorical Encoding)

Cài đặt và so sánh **5 phương pháp mã hóa**:

1. **One-Hot Encoding** (low-cardinality ≤ 20 giá trị).
2. **Ordinal Encoding** (tất cả cột phân loại, thêm hậu tố `_ord`).
3. **Target Encoding** với 5-fold CV: $\hat{x}_i = \mathbb{E}[y \mid x = x_i]$ – CV bắt buộc để tránh target leakage.
4. **Binary Encoding** (high-cardinality > 20 giá trị): $\lceil \log_2 k \rceil$ cột thay vì k cột.
5. **Frequency Encoding**: $\hat{x}_i = P(x = x_i)$ (thêm hậu tố `_freq`).

Với mỗi phương pháp, tính **VIF** (Variance Inflation Factor = $\frac{1}{1 - R_j^2}$); VIF > 10 biểu thị đa cộng tuyến.

4.3.5 Lựa chọn và giảm chiều đặc trưng (Feature Selection)

Ba tầng lựa chọn đặc trưng:

Tầng 1 – Lọc thống kê (trên mẫu 30.000 dòng):

- ANOVA F-test (thuộc tính số).
- Chi-square: $\chi^2 = \sum \frac{(O-E)^2}{E}$ (thuộc tính phân loại).
- Mutual Information: $I(X; Y) = \sum p(x, y) \cdot \log \frac{p(x, y)}{p(x)p(y)}$.

Tầng 2 – Dựa trên mô hình:

- Random Forest importance (Gini, `n_estimators=100`, `max_depth=6`).
- Gradient Boosting importance (`n_estimators=100`, `max_depth=4`).
- RFE với Logistic Regression (5-fold CV, $k \in \{5, 10, 15, 20\}$, mẫu 3.000 dòng).

Tầng 3 – Giảm chiều:

- PCA: $k^* = \min k$ sao cho $\sum \lambda_i / \sum \lambda \geq 0,95$ và 0,99.
- t-SNE 2D ($n = 3000$, perplexity=30, max_iter=500) – trực quan hóa.
- UMAP ($n_neighbors = 15$, $min_dist = 0,1$) – nếu có cài đặt.

Kết quả lựa chọn: Union top-20 đặc trưng từ RF + GB (model-based) cho kết quả cross-validation F1-score tốt nhất.

4.3.6 Xử lý mất cân bằng lớp (Class Imbalance)

- **Tỉ lệ fraud:** $\approx 3,5\%$ (Normal:Fraud $\approx 28 : 1$).
- Ba chiến lược resampling được so sánh: **SMOTE**, **ADASYN**, **Random Under-sampling**.

Công thức SMOTE: $x_{\text{new}} = x_i + \lambda \cdot (x_{knn} - x_i)$, $\lambda \sim \text{Uniform}(0, 1)$.

Công thức ADASYN: $g_i = G \cdot \hat{r}_i$, trong đó $\hat{r}_i \propto$ tỉ lệ k-NN từ lớp đối lập.

Nguyên tắc: resampling **chỉ được áp dụng trên tập train**; tập test luôn giữ nguyên phân phối gốc không cân bằng.

Chiến lược	Precision	Recall	F1-macro	AUC-ROC
Không resampling	–	–	–	–
SMOTE	–	–	–	–
ADASYN	–	–	–	–
RUS	–	–	–	–

Bảng 12: So sánh các chiến lược xử lý mất cân bằng lớp (kết quả tính tại runtime)

5 PHẦN 3: TIỀN XỬ LÝ DỮ LIỆU VĂN BẢN

5.1 Mô tả tập dữ liệu

Tập dữ liệu được sử dụng là **RAGTruth** (wandb/RAGTruth-processed trên Hugging-Face), một tập dữ liệu đánh giá khả năng hallucination của các mô hình ngôn ngữ lớn (LLM) trong các hệ thống RAG (Retrieval-Augmented Generation).

Thuộc tính	Giá trị
Số mẫu	≈ 18.000 (đảm bảo ≥ 10.000)
Nhãn phân loại	2 lớp: Supported (0, không hallucination) và Hallucinated (1)
Cột bổ sung	<code>task_type</code> (nhiều loại task), <code>model</code> (nhiều LLM)
Bài toán	Phát hiện hallucination nhị phân
Nguồn	HuggingFace – <code>wandb/RAGTruth-processed</code>

Bảng 13: Thông tin tập dữ liệu RAGTruth

5.2 Phân tích thống kê văn bản (Text EDA)

5.2.1 Phân phối độ dài văn bản

Tính và vẽ phân phối 3 chỉ số độ dài theo nhãn lớp: số từ (word count), số ký tự (char count), số câu (sentence count).

Kiểm định Mann-Whitney U test: kiểm tra sự khác biệt phân phối độ dài giữa hai lớp (Supported vs. Hallucinated). Effect size $r = Z/\sqrt{N}$. p -value và r được in ra tại runtime.

5.2.2 Word Cloud và Type-Token Ratio

- Vẽ word cloud toàn tập và riêng từng lớp.
- Bảng top-50 từ phổ biến nhất theo từng lớp.
- **Type-Token Ratio (TTR)** = $\frac{\text{unique_types}}{\text{total_tokens}}$ – đánh giá độ phong phú từ vựng theo lớp.
- Kiểm định Mann-Whitney U test trên TTR giữa hai lớp.

5.2.3 Phân tích phân phối Zipf

Vẽ **log-log plot** (tần suất từ vs. xếp hạng) và hồi quy OLS (`statsmodels.OLS`) để ước lượng α trong:

$$\log f(r) = -\alpha \cdot \log r + C$$

Kết quả: $\alpha \approx 1,63$ (lệch khỏi $\alpha = 1,0$ lý tưởng – corpus có sự chi phối mạnh của một số ít từ tần số cao). Phân tích riêng cho từng lớp (Supported và Hallucinated).

5.3 Các kỹ thuật tiền xử lý và phân tích tác động

5.3.1 Pipeline chuẩn hóa văn bản (9 bước)

Bước	Tên bước	Mô tả
1	lowercase	Chuyển về chữ thường
2	remove_html	Loại bỏ thẻ HTML
3	remove_url	Loại bỏ URL
4	remove_email	Loại bỏ địa chỉ email
5	remove_mention	Loại bỏ @mention
6	remove_hashtag	Loại bỏ #hashtag
7	remove_number	Loại bỏ số (có điều kiện)
8	remove_punct	Loại bỏ ký tự đặc biệt
9	normalize_ws	Chuẩn hóa khoảng trắng

Bảng 14: Pipeline chuẩn hóa văn bản 9 bước

Với mỗi bước, tracking: Vocab Size, Δ Vocab%, Mean Tokens/Doc, Δ Length%. `remove_punct` và `lowercase` đóng góp biến đổi từ vựng nhiều nhất.

5.3.2 So sánh chiến lược Tokenization

Chiến lược	Thư viện	Vocab Size	OOV Rate	Mean Tokens/Doc
Word-level (NLTK)	<code>word_tokenize</code>	—	—	—
Word-level (spaCy)	<code>en_core_web_sm</code>	—	—	—
Sentence-level	NLTK	—	—	—
Character-level	—	—	—	—
Subword BPE	<code>tokenizers</code> HuggingFace (vocab=10K)	—	—	—

Bảng 15: So sánh 4 chiến lược tokenization (kết quả tính tại runtime)

OOV rate được tính trên split 80/20 train/test.

5.3.3 Loại bỏ Stop Words và Phân tích thông tin

- NLTK English stop word list: **179 từ**.
- So sánh kích thước từ vựng trước/sau; tỉ lệ token bị loại bỏ.
- **Mutual Information (MI)**: `mutual_info_classif` (max_features=5.000); MI trung bình trước/sau: ΔMI_MEAN (tính động).
- Naïve Bayes 5-fold F1-macro: với stop words vs. không stop words.

- **Kiểm định Wilcoxon signed-rank**: so sánh F1 scores; **Cohen's d** đo kích thước hiệu ứng.
- **Kết luận**: loại bỏ stop words không luôn cải thiện kết quả phân loại.

5.3.4 Stemming, Lemmatization và So sánh định lượng

Phương pháp	Thư viện	Collision Rate	LR 5-fold F1
Porter Stemmer	NLTK	Cao nhất	–
Snowball Stemmer	NLTK	Trung bình	–
WordNet Lemmatizer	NLTK	Thấp nhất	–

Bảng 16: So sánh stemming và lemmatization (kết quả runtime)

Collision Rate = $1 - \frac{\text{unique_results}}{\text{unique_inputs}}$ – thứ tự: Porter > Snowball > WordNet (WordNet bảo toàn ngữ nghĩa tốt nhất).

Kiểm định Friedman χ^2 + pairwise Wilcoxon (Bonferroni) trên 5-fold F1-macro.

5.3.5 Vector hóa văn bản (Vectorization)

Cài đặt **tự xây dựng** (không dùng `sklearn.TfidfVectorizer`):

- **BoW (Bag-of-Words)**: `_build_vocab()` → `_bow_transform()` dùng `scipy.sparse.csr_matrix` (`max_features=10.000`, unigram).
- **TF-IDF**: $\text{IDF} = \log\left(\frac{1+N}{1+df}\right) + 1$; L2 normalization per document.
 - Unigram ($n = 1$), Bigram ($n \in \{1, 2\}$), Trigram ($n \in \{1, 2, 3\}$) – cả 3 qua hàm `_tfidf_from_bow()`.
- **Word2Vec** (gensim): `vector_size=100`, `window=5`, `min_count=2`, `epochs=20`, CBOW; vector tài liệu = mean of word vectors.

Các chỉ số đánh giá cho mỗi biểu diễn:

- Số chiều và sparsity ratio: $1 - \frac{\text{nnz}}{\text{rows} \times \text{cols}}$ (BoW: > 99%).
- Cosine similarity giữa (i) các văn bản cùng lớp Supported, (ii) cùng lớp Hallucinated, (iii) khác lớp.
- Silhouette Score – đánh giá khả năng tách lớp.
- t-SNE 2D visualization tô màu theo nhãn.

Biểu diễn	Số chiều	Sparsity	Silhouette	SVM F1-macro
BoW unigram	10.000	>99%	–	–
TF-IDF unigram	10.000	>99%	–	–
TF-IDF bigram	–	>99%	–	–
TF-IDF trigram	–	>99%	–	–
Word2Vec	100	0%	–	–
Sentence Transformer	384	0%	–	–

Bảng 17: So sánh các phương pháp vector hóa văn bản (kết quả runtime)

5.3.6 [Nâng cao] Biểu diễn ngữ nghĩa bằng Sentence Transformer

- Mô hình: **all-MiniLM-L6-v2** (384 chiều, dense embeddings), **batch_size=128**.
- **K-Means** ($k = 2$) so sánh TF-IDF (TruncatedSVD 100 chiều) vs. Sentence Transformer: Silhouette Score.
- **Linear SVM** (LinearSVC, max_iter=5.000): 5-fold F1-macro cho TF-IDF, Word2Vec, Sentence Transformer.

Kết quả: TF-IDF silhouette > Sentence Transformer silhouette – TF-IDF phân tách tốt hơn cho $k = 2$. Nguyên nhân: task phát hiện hallucination phụ thuộc nhiều vào tín hiệu từ vựng bề mặt hơn là ngữ nghĩa sâu.

5.4 Bảng xếp hạng phân loại cuối cùng

Mô hình	Biểu diễn	5-fold F1-macro
Naïve Bayes	BoW	–
Naïve Bayes	TF-IDF unigram	–
Naïve Bayes	TF-IDF bigram	–
Logistic Regression	TF-IDF unigram	–
Logistic Regression	TF-IDF bigram	Cao nhất
Linear SVM	TF-IDF bigram	–
Linear SVM	Word2Vec	–
Linear SVM	Sentence Transformer	–

Bảng 18: Bảng xếp hạng phân loại cuối cùng trên RAGTruth

Kết luận: **Logistic Regression + TF-IDF bigram** đạt F1-macro cao nhất. Dense embeddings (Sentence Transformer) không tự động vượt trội TF-IDF; hiệu quả phụ thuộc vào đặc tính dữ liệu và bài toán.

6 PHÂN TÍCH SO SÁNH TỔNG HỢP

6.1 Tổng hợp lựa chọn pipeline

Phần	Quyết định	Lý do
Ảnh	Resize: 128×128	Cân bằng SSIM và chi phí tính toán
	Color space: RGB (baseline)	HSV tốt hơn cho k-NN nhưng RGB tổng quát hơn
	Normalization: Z-score per-channel	Kiểm soát tốt chênh lệch giữa các kênh
	Augmentation: 6 phép biến đổi kết hợp	Wilcoxon $p < 0,05$ – tăng diversity
Bảng	Imputation: Median	MICE OOM; Median ổn định và hiệu quả
	Outlier: IQR Clipping	Bảo toàn số hàng, không xóa dữ liệu
	Scaling: RobustScaler	399/400 không chuẩn; bền với outlier
Văn bản	Tokenization: Word-level (NLTK)	OOV thấp; cân bằng vocab/độ dài
	Vectorization: TF-IDF bigram + LR	F1-macro cao nhất trên 5-fold CV

Bảng 19: Tổng hợp các lựa chọn pipeline cuối cùng

6.2 Thảo luận

Phần 1 – Ảnh: Việc chọn NWPU-RESISC45 với 45 lớp cân bằng là lý tưởng cho ablation study vì loại bỏ được yếu tố nhiễu từ class imbalance. Hạn chế chính: k-NN trên pixel features không phản ánh được khả năng học đặc trưng sâu của CNN – các kết luận về augmentation và color space có thể khác biệt đáng kể khi dùng feature extractor học sâu.

Phần 2 – Dữ liệu bảng: Tập IEEE-CIS có tỉ lệ missing cực cao (nhóm Identity: 84,5%) và mất cân bằng lớp nghiêm trọng (28:1) – đây là hai thách thức lớn nhất. Việc chọn Median thay vì MICE là sự đánh đổi thực tế giữa hiệu năng và khả năng tính toán. Với dữ liệu thực tế quy mô lớn, cân nhắc dùng MissForest hoặc deep learning imputation như GAIN là hướng cải tiến tiềm năng.

Phần 3 – Văn bản: RAGTruth là tập dữ liệu thú vị và hiện đại (hallucination detection cho LLM RAG systems). Kết quả cho thấy TF-IDF vẫn cạnh tranh mạnh với Sentence Transformer trong các task phân loại nhị phân có tín hiệu từ vựng rõ ràng. Hạn chế: corpus tiếng Anh, không kiểm tra cross-lingual; Zipf $\alpha = 1,63$ cho thấy corpus khá chuyên biệt (responses của LLM) so với văn bản tự nhiên thông thường ($\alpha \approx 1,0$).

7 KẾT LUẬN

Đồ án đã hoàn thành đầy đủ các yêu cầu bắt buộc cho Phần 1 (ảnh), Phần 2 (bảng) và Phần 3 (văn bản), cùng với nhiều yêu cầu nâng cao.

Điểm nổi bật về kỹ thuật:

- Toàn bộ kỹ thuật tiền xử lý đều có **đánh giá định lượng** qua kiểm định thống kê phù hợp (Kruskal-Wallis, Wilcoxon, Mann-Whitney, Friedman, KS test, ANOVA), không chỉ dừng ở quan sát trực quan.
- **Ablation study** được thực hiện có kiểm soát cho từng quyết định pipeline quan trọng.
- Effect sizes (η^2 , Cohen's d, $r = Z/\sqrt{N}$) được báo cáo bên cạnh p -values để tránh overinterpretation của kiểm định thống kê.
- Các lựa chọn pipeline cuối cùng đều có lý giải rõ ràng dựa trên kết quả định lượng.

Hướng cải tiến tương lai:

- Phần 1: Thử feature extractor CNN (ResNet, EfficientNet) thay vì pixel-level k-NN để ablation study có ý nghĩa thực tiễn hơn.
- Phần 2: Khảo sát GNN-based imputation hoặc GAIN cho tập có missing cực cao.
- Phần 3: Thử nghiệm fine-tuning BERT/RoBERTa cho task hallucination detection.

TÀI LIỆU THAM KHẢO

1. Cheng, G., Han, J., & Lu, X. (2017). Remote Sensing Image Scene Classification: Benchmark and State of the Art. *Proceedings of the IEEE*, 105(10), 1865–1883.
2. IEEE-CIS Fraud Detection Competition. Kaggle. <https://www.kaggle.com/c/ieee-fraud-detection>
3. Wu, T. et al. (2023). RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models. *arXiv:2401.00396*.
4. Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
5. He, H., Bai, Y., Garcia, E. A., & Li, S. (2008). ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning. *IEEE IJCNN*, 1322–1328.
6. Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *EMNLP 2019*. <https://www.sbert.net/>
7. Van der Maaten, L., & Hinton, G. (2008). Visualizing Data using t-SNE. *JMLR*, 9, 2579–2605.
8. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12,

2825–2830.

9. Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. *arXiv:1301.3781*.
10. Zipf, G. K. (1949). *Human Behavior and the Principle of Least Effort*. Addison-Wesley.